

# Tidsserieanalys 7,5 hp

## Föreläsning 1

Lärare: Lotta Hallberg

E-post-adress: [ann-charlotte.hallberg@liu.se](mailto:ann-charlotte.hallberg@liu.se)

Josef Wilzén

E-post-adress: [Josef.wilzen@liu.se](mailto:Josef.wilzen@liu.se)

# Kursens innehåll

- Projekt i tidsserieanalys, 1,5hp
- Skriftlig tentamen, 6hp

## **Innehåll:**

- Index
- Säsongrensning (komponentuppdelning)
- Tidsserieregression
- Exponentiell utjämning
- ARIMA/SARIMA modellering
- Några mer avancerade metoder

# Kursens upplägg

- LISAM, Teams
- Föreläsningar, Lektioner, Datorlaborationer
- Litteratur:
  - Index, kompendium skrivet av Anders Nordgaard
  - Introduction to TIME SERIES ANALYSIS AND FORECASTING Montgomery, Wiley
  - Plus en bok
- Datorlaborationer
  - Träning på olika moment
  - Två timmar bokad tid för varje laboration
  - Minitab och R
- Examination. Projekt och skriftlig salstentamen
  - Viktigt att labbarna är genomförda för att klara dessa moment
  - Hjälpmedel på tentan: Räknedosa. **Två handskrivna eller digitalt skrivna A4 blad med egna anteckningar** (båda sidor).
  - För godkänt krävs minst 12 av 20 poäng och för väl godkänt krävs minst 16 av 20 poäng.

# Tidsserieanalys

## Kapitel 1

- Data som observeras över tid
  - Kan ha olika tidsenhet: år, kvartal, månad, vecka, dag, timme, sekund
- Tidserien ska vara:
  - Samplad med regelbundna intervall
- Vi vill...
  - Förstå tidserien
  - Göra prognoser (forecast) för framtiden

# Vilka särdrag har tidsseriedata?

## Varför behövs nya metoder?

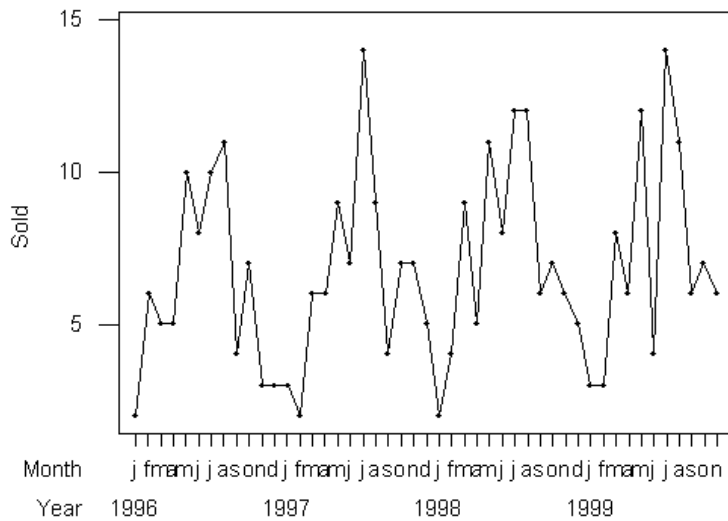
- Observationerna är inte oberoende, eftersom det finns ett beroende i tiden
- Det är samma tidsavstånd mellan alla observationer.
- Inga observationer saknas.
- Observationerna ger ett mönster över tiden
  - en trend: fallande eller stigande värden med tiden
  - en periodisk variation över en tidsperiod av bestämd längd (säsongeffekter eller liknande)
  - konjunktursvängningar
  - förändringar pga regeländring, förändrad definition av y-variabeln osv

# Exempel på tidsseriedata


- Olika typer av ekonomiska data:
  - Arbetslöshetssiffror
  - Försäljningsvärden i ett företag
  - Konsumentprisindex och andra index
  - Export- och importmängder
- Miljömätdata:
  - Fosforhalt i havsvattenbassänger
  - Ozonhalt i luftrummet över en storstad
- Medicinska data:
  - Antal fall av viss sjukdom (influensa, påssjuka ...)

# Introduktion till tidsserier


Number of homes sold per month



Time Series Plot of Sold




Scatterplot of Sold vs t



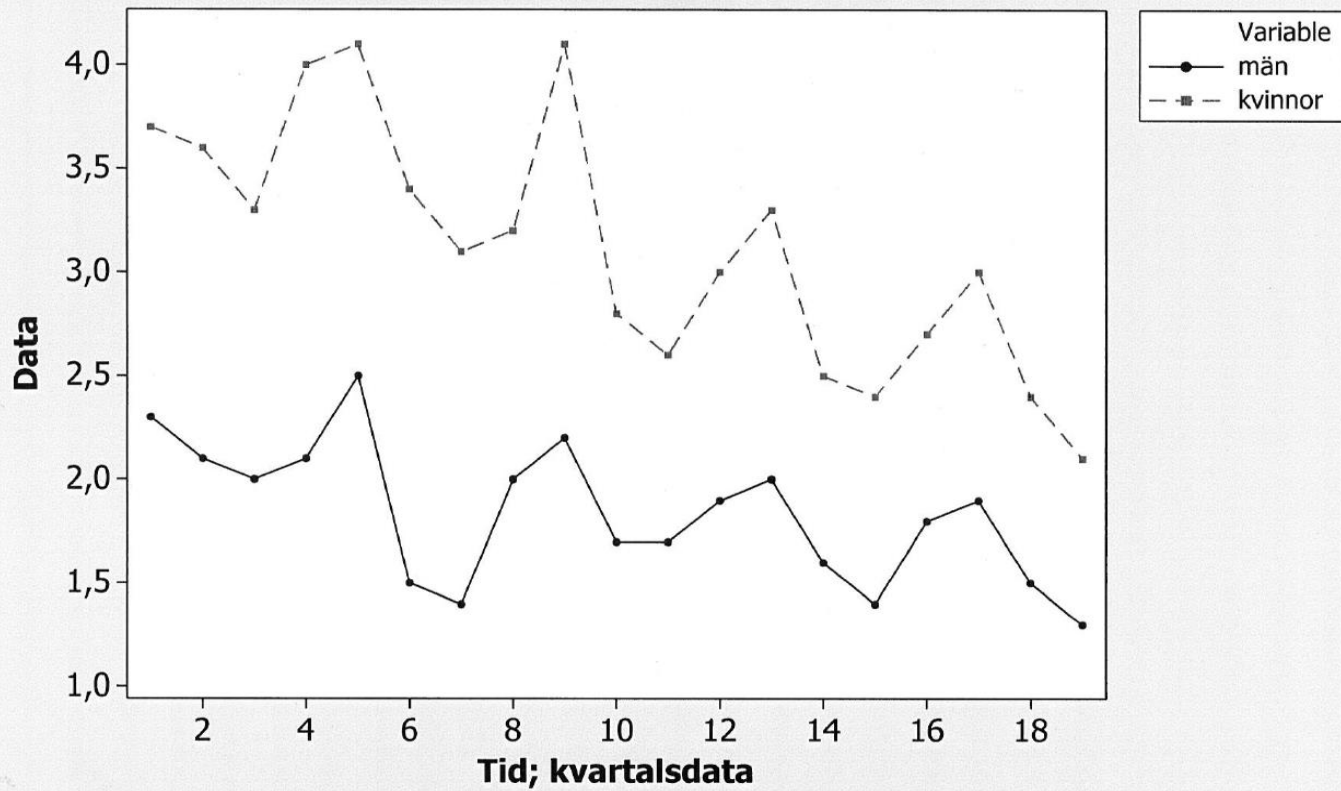
# Tidsserieanalys

OMX30 24-08-09 till 24-09-10






### Andel sjukfrånvaro för män resp kvinnor




# Antal turister till Turkiet


## Månadsdata




# Månadsdata över pappersproduktion jan 1990 till okt 2004




# Försäljning kläder och skor jan 1990 till sep 2004




# Bränsleförbrukning, naturgas kvartal 1, 1992 till kvartal 4, 2001



# Andel arbetslösa jan 1987 till dec 2002



# Antal lastbilsregistreringar jan 1975 till nov 2004



# Tidsserieanalys

- En tidsserie har diskreta tidpunkter
  - Vid kontinuerlig tid så har vi en stokastisk process
- Inga saknade värden
  - Imputera om något värde saknas
- Man mäter samma sak genom hela serien
  - Ex: arbetslöshetsdata. Är definitionen på arbetslöshet samma genom hela serien
- Vilken upplösning har serien?
  - År, månad, kvartal, vecka, dag, timme osv



**Statiska tidsseriemodeller** som kan beskriva tidsserien och även producera prognoser

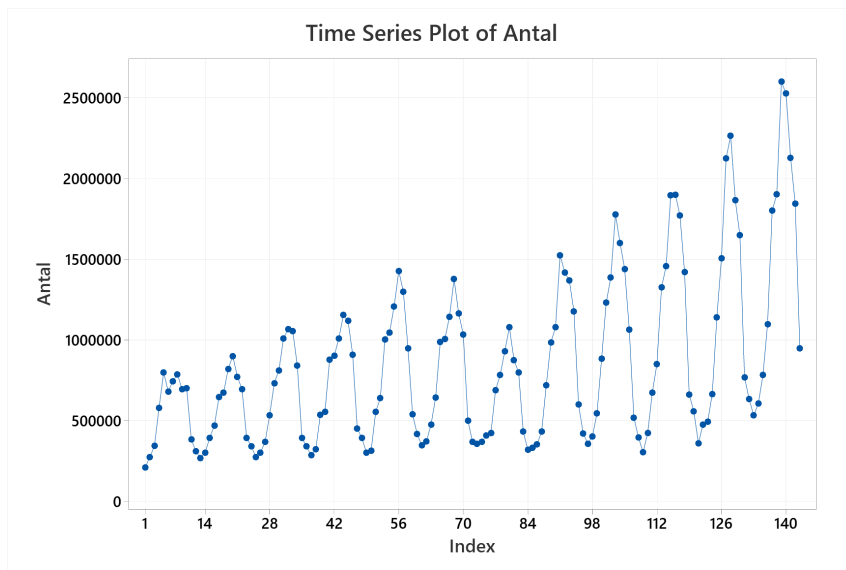
1. Anpassad modell för tidsserieregression kan användas för att göra prognoser för framtida tidpunkter samt tolka mönster.
2. Klassisk modell för komponentuppdelning kan göra prognoser med hjälp av trend- och säsongskomponenter, men i viss mån även beträffande konjunktur samt även tolka vissa mönster.

**Dynamiska tidsseriemodeller** som framförallt syftar till att göra prognoser

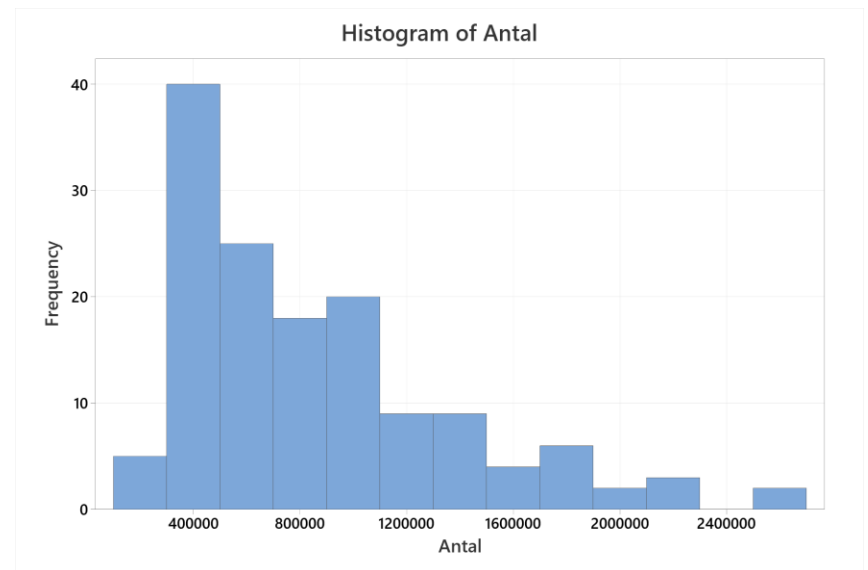
3. Exponentiella utjämningsmodeller
4. Autoregressiv modellering. SARIMA-modeller

# Grafiska metoder Kap 2,2

Antal turister




Antal turister

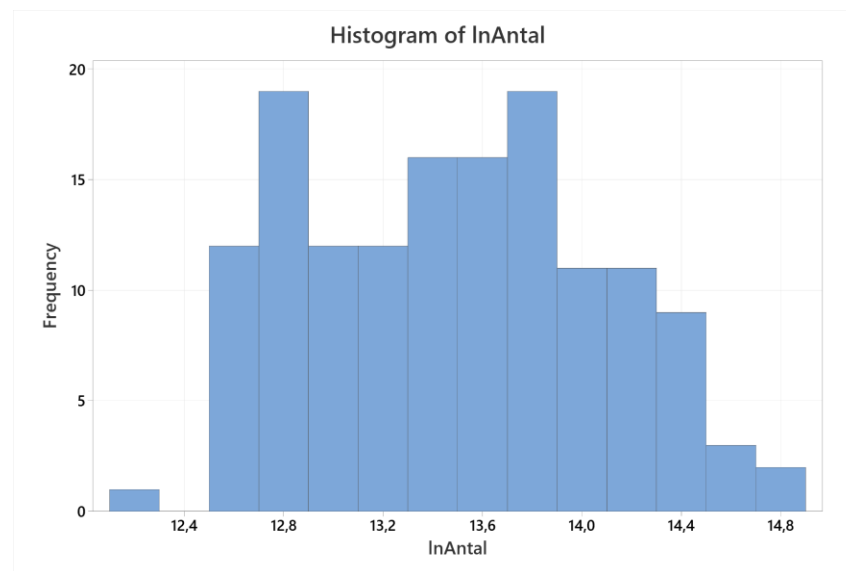


# Transformera kap 2,4,1

In Antal



In Antal



# Prognosprocess

## Forecasting Kap 1,3

- Identifiera problemet
- Samla in data
- Analysera tidsserien
- Hitta en lämplig modell
- Validera modellen
- Gör prognos
- Utvärdera prognos

# Kapitel 2,1

## Några grundläggande begrepp

- Låt  $y_t$ ,  $t = 1, 2, \dots, T$  vara tidsserien
- Vi har en observation av slumpvariabeln  $y_t$  vid varje tidpunkt  $t$ .
- Låt  $\tau$  beteckna antalet tidpunkter fram i tiden som vi vill göra prognos för (eng. Lead time)
- Låt  $\hat{y}_{t+\tau}(t)$  beteckna prognos för  $y$  för tidpunkt  $t + \tau$  då vi står vid tidpunkt  $t$  när vi gör prognosen
- Då gäller även  $\hat{y}_t(t - \tau)$  är prognos för  $y_t$  gjord vid tidpunkt  $t - \tau$
- Prognosfel  $e_t(\tau) = y_t - \hat{y}_t(t - \tau)$
- Om  $\tau = 1$  så är  $e_t(1) = e_t = y_t - \hat{y}_t(t - 1) = y_t - \hat{y}_t$
- Vi vill ha små prognosfel.

# Kapital 2,6

## Valideringsmått

- Vi ska titta på tre mått MSD, MAD och MAPE
- Alla tre är mått på hur bra anpassningen är och kan användas för att jämföra olika modeller. Den modell som har lägst MAPE, MAD och/eller MSD har bäst anpassning.
- Oftast visar alla 3 måtten åt samma håll. Men i vissa fall kan man vara tvungen att välja ett av dem.
- Vid val mellan t ex additiv modell och multiplikativ modell kan det hända att något av måtten är högre för den ena modellen medan ett annat mått är lägre. Det gäller alltså att tolka måtten med visst förnuft.

MSD kan också jämföras med  $MSE$  i den multipla regressionsmodellen:

$$MSD = \frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2 \quad \text{Mean Square Deviation}$$

$$MSE = \frac{1}{n-k-1} \sum_{t=1}^n (y_t - \hat{y}_t)^2 \quad \text{Mean Square Error}$$

$$MAD = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t| \quad \text{Mean Absolute Deviation}$$

*MAD* är mindre känslig för avvikande värden och blir mer användbar när vi har något enstaka värde som uppträder konstigt.

Ytterligare en fördel med *MAD* är att dess värde är i samma skala som  $y_t$  observationerna själva, vilket gör det lättare att tolka.



$$MAPE = \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right| \quad \text{Mean Absolute Percentage Error}$$

Måttet använder också absoluta avvikelser, men mäter dem relativt nivån hos  $y$ . Vi får alltså relativa (procentuella) avvikelser.

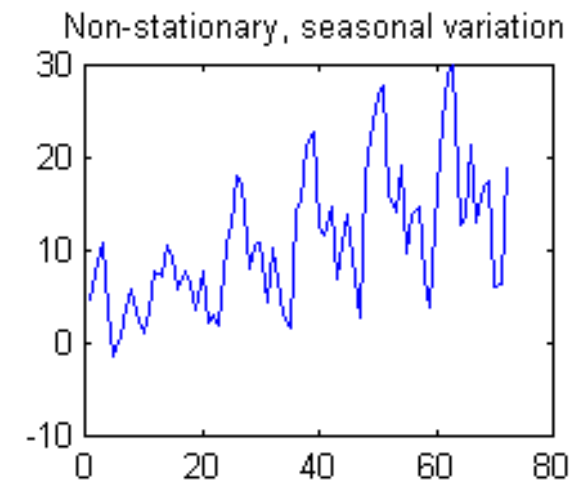



Måttet är praktiskt för multiplikativa modeller där den oregelbundna (slump) komponenten ( $IR_t$ ) är ganska betydande, eftersom avvikelserna då blir stora när vi har stora värden på  $y$ .

# Stationäritet Kap 2,3

En tidsserie är stationär om följande gäller:

- Tidsserien ska ha ett konstant väntevärde över tiden (bortsett från säsongssvängningar).
- Tidsserien ska ha en konstant varians över tiden.
- Korrelationen mellan två tidpunkter i serien får endast bero på avståndet mellan dessa punkter, och inte på var i tiden de ligger.

## Exempel på stationära och icke-stationära tidsserier:



# Hur kan man avgöra om en tidsserie är stationär?

1. Studera grafen över tidsserien (trender och dylikt syns i regel tydligt)
2. Beräkna och studera den skattade *autokorrelationsfunktionen*, SAC = sample autocorrelation-function

$$r_k = \text{Korr}(y_t, y_{t+k}) \text{ för } k = 1, 2, 3, \dots$$


Denna ska avta relativt snabbt mot 0 för att serien ska vara stationär.

# SAC

SAC är den skattade autokorrelationen. Sample AutoCorrelation


$$\text{SAC: } \widehat{\text{Korr}}[z_t, z_{t+k}] = r_k = \frac{\sum_{t=1}^{T-k} (z_t - \bar{z})(z_{t+k} - \bar{z})}{\sum_{t=1}^T (z_t - \bar{z})^2}$$

Scatterplot of Kemisk process vs Tid



# SAC Se sid 40 l boken

**Autocorrelation Function for Kemisk process**  
(with 5% significance limits for the autocorrelations)



# Differentiering kap 2,4 sid 50 →

Om tidsserien inte är stationär så kan tidsserien differentieras tills den blir stationär.

- Den stationära tidsserien betecknas  $z_t$ .
- Originaltidsserien betecknas  $y_t$
- Andra beteckningar på en tidsserie kan vara  $w_t$   $v_t$  osv



Om trend ses i tidsserien:

Differentiera originalserien med 1 tidsförskjutning

$$z_t = y_t - y_{t-1} = \text{Diff1}$$

Om  $y_t$  uppvisar en kvadratisk trend differentierar man två gånger, dvs

$$w_t = y_t - y_{t-1} \quad \text{och sedan}$$

$$z_t = w_t - w_{t-1} = \text{Diff1,1}$$

Om kraftig säsongsvariation finns så kan vi differentiera för säsong:

$$z_t = y_t - y_{t-L} = \text{Diff}L$$

där  $L$  är säsongslängden

Månadsdata:

$$z_t = y_t - y_{t-12} = \text{Diff}12$$

Kvartalsdata:


$$z_t = y_t - y_{t-4} = \text{Diff}4$$

Vi kanske måste differentiera både för trend och säsong:

$$w_t = y_t - y_{t-1} = \text{Diff}1$$

$$z_t = w_t - w_{t-L} = \text{Diff}1, L$$


$\text{Diff}L, 1$  ger samma resultat




Ursprungliga tidsserien:  
 inte stationär  
 Månadsdata

Differentierad serie (förändring  
 från månad till månad):

stationär




# Exempel: Försäljning av tandkräm



t	$y_t$	$y_{t-1}$
1	49	*
2	51	49
3	51	51
4	55	51
5	52	55
6	55	52
OSV		55

#### Diff1

49-\*=\*  
 51-49=2  
 51-51=0  
 55-51=4  
 52-55=-3  
 55-52=3  
 OSV



$B$  = bakåtskiftoperator

$By_t = y_{t-1}$      $B$  kan bara operera från vänster

Difference     $(1 - B)y_t = y_t - y_{t-1}$

$B^2y_t = y_{t-2}$      $B^2 = BB$

$B^{12}y_t = y_{t-12}$

$(1 - B^{12})y_t = y_t - y_{t-12}$

$(1 - B)^2y_t = (1 - B)(y_t - y_{t-1})$

# Detta var genomgång av:

Kapitel 1 och mycket ur kapitel 2.

(ej variogram 2,3,3) 2,4 Endast log transformation i 2,4,1

(ej 2,6,3)