

# Föreläsning 6

# ARIMA-modellering

Kapitel 5

# ARIMA

Auto Regressive Integrated Moving Average

Modellen består av tre delar

Auto Regressive AR

Integrated I (har med differentiering att göra)

Moving Average MA (modellering av feltermen)

# Autoregressiva modeller

Istället för att tvinga in ett antal bestämda komponenter (trend, säsong, cyklisk komponent) kan man låta tidsserien successivt "förklara sig själv":

Den enklaste modellen är en AR(1):

$$y_t = \delta + \phi_1 y_{t-1} + a_t$$

- $a_t$  är normalfördelad slumpterm (vitt brus) med väntevärde 0 och konstant varians. Ej observerbar
- Värdet i tidpunkt  $t$  antas främst bero av värdet vid tidigare tidpunkter och ev. av motsvarande säsongtidpunkt föregående år.
- Parametrarna kan ibland skattas med Minsta-Kvadrat-metoden (som i regression), men vanligare är Maximum-Likelihood-metoden.

$$\text{AR}(1): y_t = \delta + \phi_1 y_{t-1} + a_t$$

Denna modell kan skrivas med bakåtshiftoperatorer  $B$

$$By_t = y_{t-1}$$

$$y_t = \delta + \phi_1 y_{t-1} + a_t$$

$$y_t = \delta + \phi_1 By_t + a_t$$

$$y_t - \phi_1 By_t = \delta + a_t$$

$$(1 - \phi_1 B)y_t = \delta + a_t$$

$$\Phi_1(B)y_t = \delta + a_t$$

$$\Phi_1(B) = (1 - \phi_1 B)$$

Enkel och dubbel exponentiell utjämning är specialfall av autoregressiva modeller. Dvs. autoregressiva modeller kan beskriva tidsserier med komplexare samband mellan historiska och framtida observationer.

För att kunna anpassa en autoregressiv modell krävs att tidsserien är *stationär*.

# Arbetsgång vid modellering av ARIMA

- Behöver tidsserien transformeras för att  $y_t$  ska ha konstant varians och vara normalfördelad?
- Är tidsserien  $y_t$  stationär? Differentiera tills stationäritet nås.
- Studera SAC och SPAC för att bestämma lämplig ARIMA-modell
- Anpassa vald modell och utvärdera med residualanalys.
- Studera bl a SAC på residualerna (som vanligt)
- Kan man se i SAC för residualerna att något mer behöver modelleras?
- Gör prognoser

# Stationäritet Kap 2,3 (Från Föreläsning 1)

En tidsserie är stationär om följande gäller:

- Tidsserien ska ha ett konstant väntevärde över tiden (bortsett från säsongssvängningar).
- Tidsserien ska ha en konstant varians över tiden.
- Korrelationen mellan två tidpunkter i serien får endast bero på avståndet mellan dessa punkter, och inte på var i tiden de ligger.

# Differentiering kap 2,4 sid 50 → (Från Föreläsning 1)

Om tidsserien inte är stationär så kan tidsserien differentieras tills den blir stationär.

- Den stationära tidsserien betecknas  $z_t$ .
- Originaltidsserien betecknas  $y_t$
- Andra beteckningar på en tidsserie kan vara  $w_t$   $v_t$  osv



(Från Föreläsning 1 men även med B)

Om trend ses i tidsserien:

Differentiera originalserien med 1 tidsförskjutning

$$z_t = y_t - y_{t-1} = (1 - B)y_t = \text{Diff1}$$

Om  $y_t$  uppvisar en kvadratisk trend differentierar man två gånger, dvs

$$w_t = y_t - y_{t-1} = (1 - B)y_t \text{ och sedan}$$

$$z_t = w_t - w_{t-1} = (1 - B)(1 - B)y_t = (1 - B)^2 y_t = \text{Diff1,1}$$

(Från Föreläsning 1)

Om kraftig säsongsvariation finns så kan vi differentiera för säsong:

$$z_t = y_t - y_{t-L} = (1 - B^L)y_t = \text{Diff}L$$

där  $L$  är säsongslängden

Månadsdata:

$$z_t = y_t - y_{t-12} = (1 - B^{12})y_t = \text{Diff}12$$

Kvartalsdata:

$$z_t = y_t - y_{t-4} = (1 - B^4)y_t = \text{Diff}4$$

Vi kanske måste differentiera både för trend och säsong:

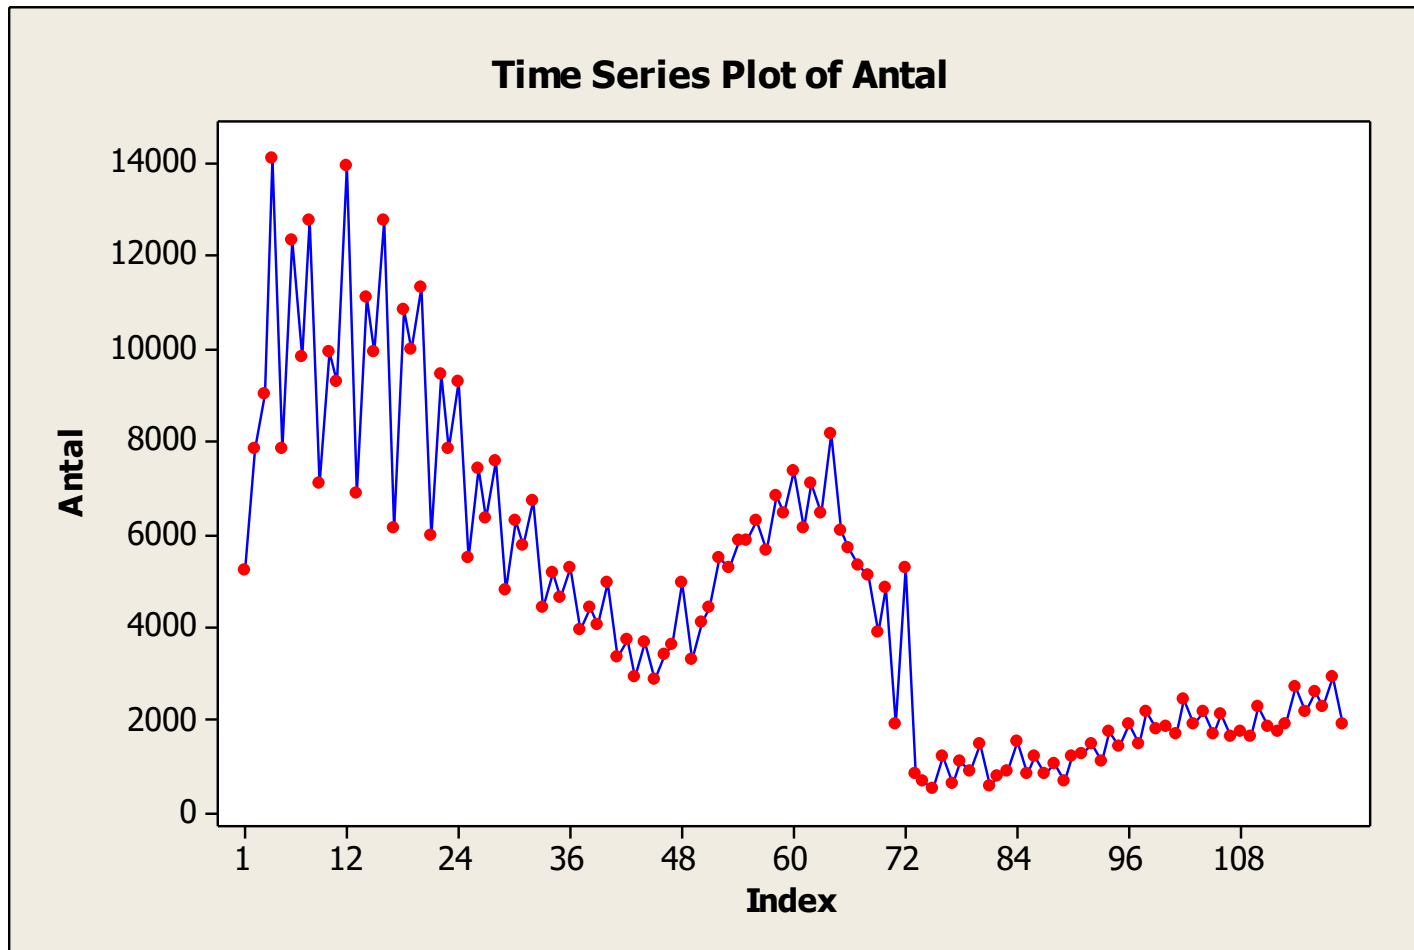
$$w_t = y_t - y_{t-1} = (1 - B)y_t = \text{Diff}1$$

$$z_t = w_t - w_{t-L} = (1 - B^L)w_t = (1 - B^L)(1 - B)y_t = \text{Diff}1, L$$

DiffL, 1 ger samma resultat

# Exempel: Antal nybyggnationer


## Kvartalsdata kv 1 1975 till kv 3 2004



Först måste vi undersöka om tidsserien har **konstant varians**.

Om den inte har det så måste vi transformera data så att konstant varians uppnås.

Antal nybyggnationer logaritmeras.  $\ln \text{Antal}$



# SAC och SPAC

SAC är den faktiska autokorrelationen.

SPAC = Sample Partial AutoCorrelation, är en 'renare' autokorrelation.

Båda är mycket viktiga för att välja rätt modell.

Tidsserien bör vara stationär när man studerar SPAC

# SAC och SPAC

$$\text{SAC: } \widehat{\text{Korr}}[z_t, z_{t+k}] = r_k = \frac{\sum_{t=1}^{n-k} (z_t - \bar{z})(z_{t+k} - \bar{z})}{\sum_{t=1}^n (z_t - \bar{z})^2}$$


$$\text{SPAC: } \widehat{\text{Korr}}[z_t, z_{t+k} | z_{t+1}, \dots, z_{t+k-1}] = r_{kk}$$

$$r_{kk} = \begin{cases} r_1 & \text{om } k = 1 \\ \frac{r_k - \sum_{j=1}^{k-1} r_{k-1,j} r_{k-j}}{1 - \sum_{j=1}^{k-1} r_{k-1,j} r_j} & \text{om } k = 2, 3, \dots \end{cases}$$


$$\text{där } r_{kj} = r_{k-1,j} - r_{kk} r_{k-1,k-j} \quad j = 1, 2, \dots, k-1$$

**SAC** på InAntal. Ej stationär. Avtar ganska långsamt.

Det är alltså i SAC vi ser om vi har stationäritet. Även i tidsseriegrafnen  
Vid stationäritet avtar SAC relativt snabbt.




# Differentiera lnAntal






**SAC** på Diff1=difflnAntal. Avtar ganska långsamt.



Serien tycks ändå inte bli stationär. Studera SPAC

# SPAC på $\text{diff1}=\text{difflnAntal}$

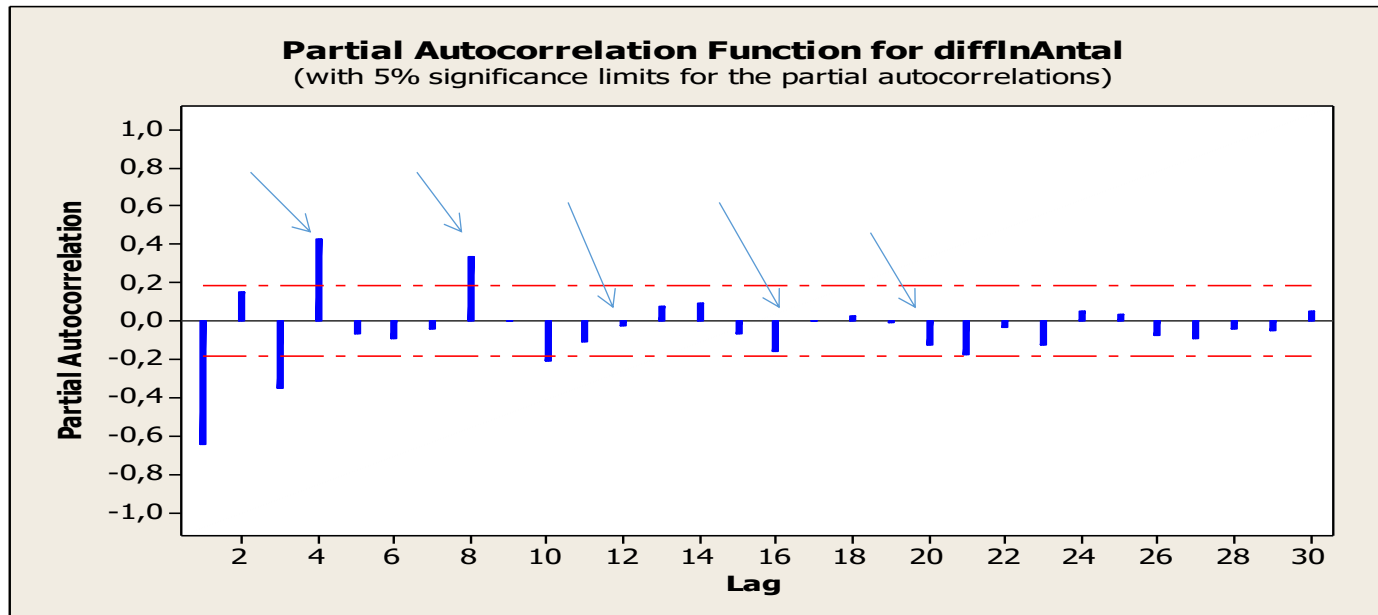


SPAC ger en 'Renare' autokorrelation.


# Tolkning SPAC

Vi ser en spik på lag 4 och lag 8. Detta påminner oss om att vi har kvartalsdata.


Vi kan nu differentiera, diffad lnAntal för säsong.



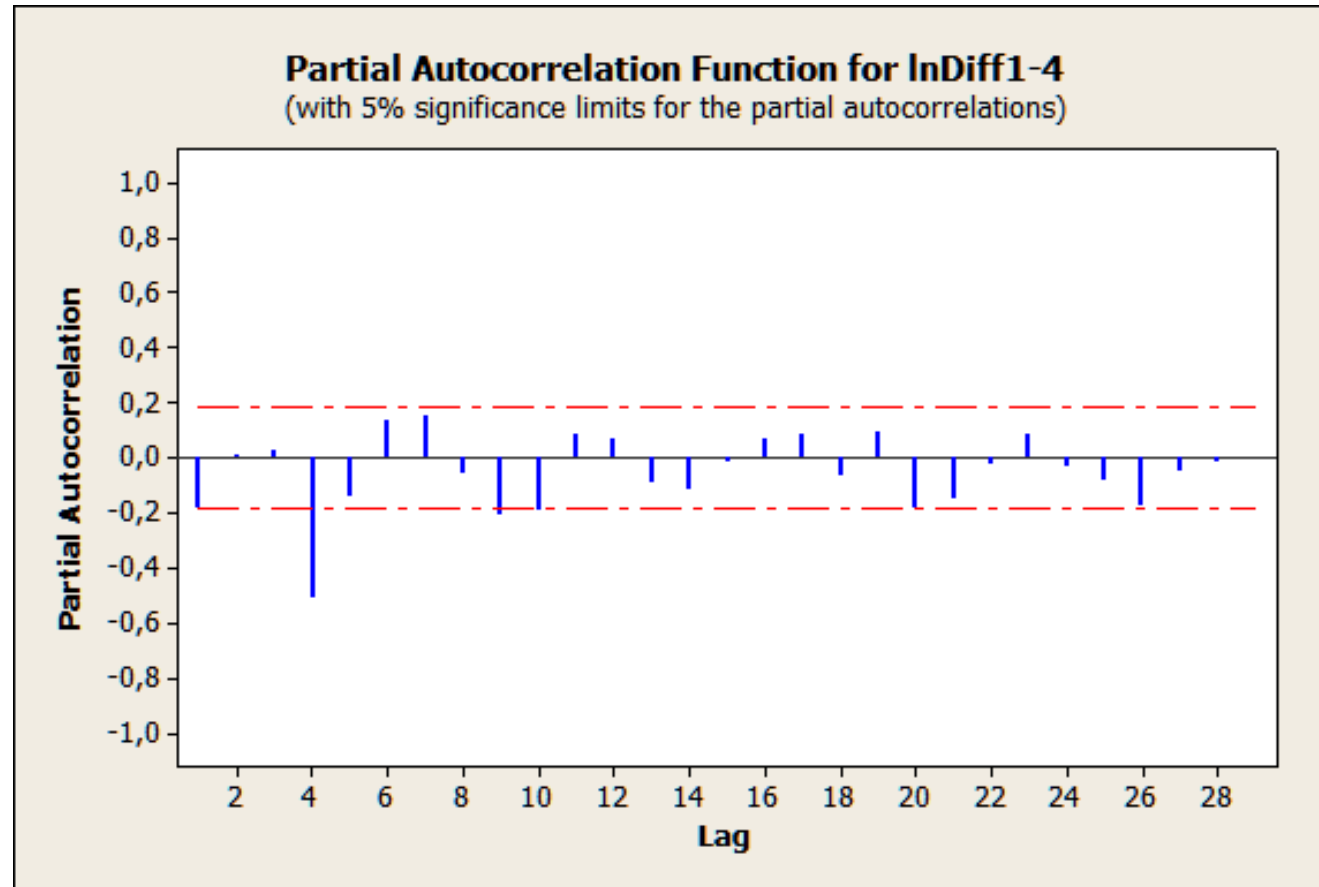
Så nedanstående graf är Diff1,4 på lnAntal



SAC på  $\ln\text{Diff}_{1,4}$ . STATIONÄR!! Yes 😊



# SPAC på $\ln \text{Diff}_{1,4}$



# Modellbestämning

Med hjälp av SAC och SPAC för den stationära tidsserien, ska vi nu gå vidare och bestämma en ARMA-modell.

Det är viktigt att inte differentiera i onödan. Vi vill INTE få bort ALLA spikar i SAC och SPAC.

# ARIMA-modell

**Auto Regressive Integrated Moving Average** modell ARIMA(p,d,q)

Låt  $y_t$ ,  $t = 1, 2, \dots, n$  vara tidsserien med  $n$  värden.

Låt vidare  $z_t$  vara den stationära tidsserien. Dvs  $y_t$  har differentierats för säsong och trend om det behövs.

AR modell med ordning  $p$  = AR(p):

$$z_t = \delta + \phi_1 z_{t-1} + \phi_2 z_{t-2} + \dots + \phi_p z_{t-p} + a_t$$

$a_t$  är **vitt brus** (=slumpterm). Alla  $a_t$  är oberoende och normalfördelade med väntevärde 0 och konstant varians.

$a_t$  kan inte observeras



AR modell med ordning  $p = AR(p)$ :

$$z_t = \delta + \phi_1 z_{t-1} + \phi_2 z_{t-2} + \dots + \phi_p z_{t-p} + a_t$$

Med bakåtskiftoperatorer  $B$

$$z_t - \phi_1 z_{t-1} - \phi_2 z_{t-2} - \dots - \phi_p z_{t-p} = \delta + a_t$$


$$(z_t - \phi_1 B z_t - \phi_2 B^2 z_t - \dots - \phi_p B^p z_t) = \delta + a_t$$

$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p) z_t = \delta + a_t$$

$$\Phi_p(B) z_t = \delta + a_t$$

$$\Phi_p(B) = (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)$$

# Simulerad tidsserie AR(1)




# Val av AR-modell

Studera SAC och SPAC för  $z_t$

SAC ska ha ett ganska snabbt avtagande mönster och

SPAC ska ha p spikar om AR(p).

Ex: AR(1)



# Simulerad tidsserie

Den tidsserie som har simulerats är

$$z_t = 0,8z_{t-1} + a_t$$

där  $a_t$  är  $N(0,1)$  och oberoende

$$t = 1, 2, \dots, 100$$

Enkelt att simulera då det är en rekursionsformel som man adderar normalfördelade slumpvärden till.

# Teori om AR(1)

$$\text{AR(1):} \quad z_t = \delta + \phi_1 z_{t-1} + a_t$$
$$E[z_t] = \frac{\delta}{1 - \phi_1}$$

Teoretisk AutoCorrelation TAC

$$\rho(k) = \text{Korr}[z_t, z_{t+k}] = \text{Korr}[z_t, z_{t-k}] = \rho(-k)$$

$$\rho(k) = \phi_1^k \quad k = 0, 1, 2, \dots$$

TAC avtar ganska snabbt. När vi studerar SAC så letar vi efter mönster som finns i TAC

Se bl a figure 5,6 sid 341

TPAC  $\neq 0$  då  $k = 1$  och noll annars Teoretisk Partiell AutoCorrelation

# Teori om AR(2)

$$\text{AR}(2): \quad z_t = \delta + \phi_1 z_{t-1} + \phi_2 z_{t-2} + a_t$$

$$E[z_t] = \frac{\delta}{1 - \phi_1 - \phi_2}$$

Teoretisk AutoCorrelation TAC

$$\rho(1) = \frac{\phi_1}{1 - \phi_2} \quad \rho(2) = \phi_1 \rho(1) + \phi_2 \quad \rho(3) = \phi_1 \rho(2) + \phi_2 \rho(1) \quad \text{osv}$$

TAC avtar ganska snabbt men kan även svänga.

Se bl a figure 5,7 och 5,8

TPAC  $\neq 0$  då  $k = 1, 2$  och noll annars

# MA-modell

Medan en AR-modell ser ut som en viss typ av regressionsmodell, autoregression,

så är MA-modellen mycket svårbegriplig. Men den är ändå mycket användbar.

Man modellerar här  $z_t$  med endast vitt brus.

MA-modell med ordning  $q = MA(q)$

$$z_t = \delta + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

MA-modell med ordning  $q = MA(q)$

$$z_t = \delta + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

Med bakåtskiftoperatorer  $B$

$$z_t = \delta + (a_t - \theta_1 B a_t - \theta_2 B^2 a_t - \dots - \theta_q B^q a_t)$$

$$z_t = \delta + (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) a_t$$

$$z_t = \delta + \Theta_q(B) a_t$$

$$\Theta_q(B) = (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q)$$



# Val av MA-modell

Studera SAC och SPAC

SAC har  $q$  spikar och

SPAC avtar ganska snabbt.

Det är det omvända jämfört med en AR-modell.

# Teori om MA(q)

$$z_t = \delta + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

Eftersom  $E[a_t] = 0$  så är  $E[z_t] = \delta$

Autokorrelationen mellan alla  $a_t$  är 0 så  $\rho(k) \neq 0$  då  $k \leq q$

# ARMA-modell

Sätt ihop en AR(p) och en MA(q) så fås en ARMA(p,q)

$$z_t = \delta + \phi_1 z_{t-1} + \phi_2 z_{t-2} + \dots + \phi_p z_{t-p} + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

SAC och SPAC är här en sammanblandning för vad som gäller för en AR(p) och en MA(q).

Man måste ofta pröva sig fram för att finna en bra modell.

Anpassa flera olika modeller och avgör vilken som är bäst.

# ARMA(p,q)

$$z_t = \delta + \phi_1 z_{t-1} + \phi_2 z_{t-2} + \dots + \phi_p z_{t-p} + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

Med bakåtshiftoperatorer

$$z_t - \phi_1 z_{t-1} - \phi_2 z_{t-2} - \dots - \phi_p z_{t-p} = \delta + a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

$$z_t - \phi_1 B z_t - \phi_2 B^2 z_t - \dots - \phi_p B^p z_t = \delta + a_t - \theta_1 B a_t - \theta_2 B^2 a_t - \dots - \theta_q B^q a_t$$


$$(1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p) z_t = \delta + (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) a_t$$

$$\Phi_p(B) z_t = \delta + \Theta_q(B) a_t$$

$$\Phi_p(B) = (1 - \phi_1 B - \phi_2 B^2 - \dots - \phi_p B^p)$$

$$\Theta_q(B) = (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q)$$

# Ex: Pappersproduktion



Vi ska följa detta ex.

Som ses finns det säsongsvariation och detta kan vi modelleras med en ARIMA-modell. När säsong modelleras så kan den kallas SARIMA


Att hitta en SARIMA-modell väntar vi med en stund.

På något sätt måste vi ta bort den kraftigaste **säsongsvariationen**.  
Vi prövar två olika sätt

1. Säsongrensa tidsserien med klassisk komponentuppdelning
2. Differentiera för säsong

# 1. Säsongrensa


Säsongrensad serie.  
Spara säsongskomponenterna.



## Seasonal Indices

Period	Index
1	0,3795
2	0,8295
3	0,7441
4	5,3920
5	3,6420
6	8,9587
7	-29,9517
8	-2,5601
9	5,8753
10	4,6399
11	5,1753
12	-3,1247


# SAC på DESE1




Inte stationär



# Diffa för trend. desediff1




# SAC på desediff1



Tidsseriegraf och SAC visar att desediff1 är stationär

# Förslag på modell för desediff1.

## Beräkna SPAC



# Minitab

The image displays three overlapping Minitab dialog boxes for configuring an ARIMA model.

**ARIMA**

Series:  ☐ Fit seasonal model  
Period:

	Nonseasonal	Seasonal
Autoregressive:	<input type="text" value="2"/>	<input type="text" value="0"/>
Difference:	<input type="text" value="0"/>	<input type="text" value="0"/>
Moving average:	<input type="text" value="0"/>	<input type="text" value="0"/>

☒ Include constant term in model  
☐ Starting values for coefficients:

Select

Graphs... Forecasts...  
Results... Storage...  
OK Cancel

**ARIMA - Graphs**

☒ Time series plot (including optional forecasts)

Residual Plots

☒ ACF of residuals  
☒ PACF of residuals

☒ Individual plots  
☐ Histogram of residuals  
☐ Normal plot of residuals  
☐ Residuals versus fits  
☐ Residuals versus order

☐ Four in one

Residuals v

Select

Help

**ARIMA - Forecasts**

Lead:   
Origin:

Storage

Forecasts:   
Lower limits:   
Upper limits:

Select

Help OK Cancel

$$\text{ARMA}(0,1)=\text{MA}(1)$$

SAC har en spik och  
SPAC avtar ganska snabbt.  
Detta är rätt tydligt

$$\text{ARMA}(1,0)=\text{AR}(1)$$

SAC avtar snabbt och  
SPAC har en spik  
  
Känns inte lika troligt men  
kan vara värt att pröva.

Vi provar att anpassa både en MA(1) och en AR(1)

ARMA(0,1)  
= MA(1)

# ARIMA Model: desediff1

Final Estimates of Parameters


Type		Coef	SE Coef	T	P
MA	1	0,6522	0,0577	11,31	0,000
Constant		0,21802	0,09463	2,30	0,022
Mean		0,21802	0,09463		

Number of observations: 177

Residuals: SS = 2273,62 (backforecasts excluded)  
MS = 12,99 DF = 175

Modified Box-Pierce (Ljung-Box) Chi-Square statistic				
Lag	12	24	36	48
Chi-Square	13,8	26,7	33,8	48,9
DF	10	22	34	46
P-Value	0,182	0,223	0,476	0,357

# SAC på residualerna för MA(1)



# ARMA(1,0) = AR(1)

**ARIMA Model: desediff1**

Final Estimates of Parameters

Type		Coef	SE Coef	T	P
AR	1	-0,4172	0,0687	-6,07	0,000
Constant		0,2938	0,2839	1,04	0,302
Mean		0,2073	0,2003		

Number of observations: 177

Residuals: SS = 2495,89 (backforecasts excluded)


MS = 14,26 DF = 175

Modified Box-Pierce (Ljung-Box) Chi-Square statistic

Lag	12	24	36	48
Chi-Square	25,9	38,9	48,3	65,4
DF	10	22	34	46
P-Value	0,004	0,015	0,054	0,032



# SAC på residualerna för AR(1)



# Vilken modell är bäst

- T-kvoter
- MSE
- Residualanalys

# ARIMA(p,d,q)

d anger hur många differentieringar för trend vi gjort.

I vår modell är  $d=1$ .

Vald modell är ARIMA(0,1,1)

Låt Minitab diffa automatiskt.

Så nu skattar vi återigen de skattade parametrarna i den valda modellen

### ARIMA Model: DESE1

Final Estimates of Parameters

Type		Coef	SE Coef	T	P
MA	1	0,6522	0,0577	11,31	0,000
Constant		0,21802	0,09463	2,30	0,022

Differencing: 1 regular difference

Number of observations: Original series 178, after differencing 177

Residuals: SS = 2273,62 (backforecasts excluded)  
MS = 12,99 DF = 175

Modified Box-Pierce (Ljung-Box) Chi-Square statistic

Lag	12	24	36	48
Chi-Square	13,8	26,7	33,8	48,9
DF	10	22	34	46
P-Value	0,182	0,223	0,476	0,357