

Tidsserieanalys – Föreläsning 10 (ARCH, GARCH och VAR)


Frank Miller, Department of Computer and Information Science,
Linköping University

frank.miller@liu.se

December 9, 2024

Exempel 10.1

- Y_t växelkurs SEK per EUR, 2017-01-01 till 2017-12-08



Modellering av aktie- eller valutakurs


- Vi har en aktie- eller valutakurs Y_t upp till tid $t-1$ och önskar förutsäga Y_t
- Om marknadsaktörerna hade information om att kursen kommer att stiga markant från tidpunkt $t-1$ till t , skulle de redan ha köpt aktien/valutan och därmed påverkat kursen
- Därför: rimligt att anta att väntevärdet för kursen vid tidpunkt t är detsamma som vid tidpunkt $t-1$, eller att det ökar med ett konstant belopp: (*) $E[Y_t] = Y_{t-1} + \mu$
- (*) följer om vi antar modellen: $Y_t = \mu + Y_{t-1} + \varepsilon_t$ med oberoende ε_t , $E[\varepsilon_t] = 0$
- Med $Z_t = Y_t - Y_{t-1}$ betyder det $Z_t = \mu + \varepsilon_t$, dvs. Z_t är ARMA(0,0), Y_t är ARIMA(0,1,0)
- $Y_t = \mu + Y_{t-1} + \varepsilon_t$ kallas för ”slumpvandring (med drift)”

Modellering av variabilitet

- Även om vi inte kan lära oss något om framtida medelvärden från data, vill vi lära oss något om variabiliteten (volatiliteten) för att bedöma risker
- Att kunna förutsäga osäkerhet är viktigt i finansiella sammanhang
- **Variabiliteten brukar inte vara konstant utan visar ofta upp kluster** med större variation och kluster med mindre variation
- Tanken med volatilitetskluster i verkligheten leder till idén att variansen för kommande observation beror på storleken av förändringen en tidpunkt innan
- ARCH, GARCH modeller för variansmodellering läggs till en ARIMA modell för medelvärden (här idag antar vi ARIMA(0,1,0) för medelvärdet, men man kan ha ett annat modell för andra tidsserier)

Exempel 10.1

- Y_t växelkurs SEK per EUR, 2017-01-01 till 2017-12-08
- Dagliga förändringar $Z_t = Y_t - Y_{t-1}$
- $(Z_t)^2$ och glidande medel över 15 $(Z_t)^2$ värden ("Glidande Varians")



ARCH(1)-modell

- För Y_t antar vi att feltermens varians h_t (betingat för vad som har hänt innan) är

$$h_t = \omega + \alpha_1 \varepsilon_{t-1}^2,$$

där $\omega > 0$ och $\alpha_1 \geq 0$; processen kallas då ARCH(1) (ARCH="Autoregressive Conditional Heteroscedasticity")

- Vi betraktar här slumpvandringsprocessen (ev. med drift)

$$Y_t = \mu + Y_{t-1} + \varepsilon_t,$$

med oberoende ε_t som har $E[\varepsilon_t] = 0$ och $\text{Var}(\varepsilon_t) = h_t$

ARCH(1)-modell

- Exempel 10.1 (forts.): ARCH(1)-modellering av växelkursen; resultat från R (paket rugarch)

	Estimate	Std. Error	t value	Pr(> t)
mu	0.0019	0.00167	1.16	0.247
omega	0.0006	0.00007	9.05	<0.0001
alpha1	0.1600	0.07137	2.24	0.024

$$Y_t = \mu + Y_{t-1} + \varepsilon_t; \text{Var}(\varepsilon_t) = h_t = \omega + \alpha_1 \varepsilon_{t-1}^2$$

- Tolkning?

ARCH(1)-modell

- Exempel 10.2: För en ARCH(1)-tidsserie Y_t utan drift ($Y_t = Y_{t-1} + \varepsilon_t$; $\text{Var}(\varepsilon_t) = h_t = \omega + \alpha_1 \varepsilon_{t-1}^2$) antar vi $\omega = 0,0006$, $\alpha_1 = 0,16$ och normalfördelade ε_t
- Vi har följande observationer: $y_1 = 9,71$, $y_2 = 9,70$, $y_3 = 9,90$
- Beräkna standardavvikelserna $\sqrt{h_3}$, $\sqrt{h_4}$ för tidpunkterna $t=3$ och 4. Vad är $P(Y_4 > 10)$ enligt modellen?

Observerade förändringar: $e_2 = y_2 - y_1 = -0,01$, $e_3 = y_3 - y_2 = 0,2$
 $h_3 = \omega + \alpha_1 e_2^2 = 0,0006 + 0,16 \cdot (-0,01)^2 = 0,000616$ Standardavv.: $\sqrt{h_3} = 0,0248$
 $h_4 = \omega + \alpha_1 e_3^2 = \dots \dots 0,2^2 = 0,007$ $\sqrt{h_4} = 0,0836$
 Väntevärdet för X_4 enligt modellen: $E[X_4 | X_3] = X_3 = 9,90$
 Behövade variansen är $V(X_4 | X_1, X_2, X_3) = h_4$
 $P(X_4 > 10) = P\left(\frac{X_4 - 9,9}{0,0836} > \frac{10 - 9,9}{0,0836}\right) = P(Z > 1,2) = 0,115$
 11,5% risk att växelkursen överstiger 10 kr per EUR nästa dag

ARCH(q)- och GARCH(p,q)-modell

- Om feltermens varians h_t för Y_t får beror på q stycken tidigare ε_t ,

$$h_t = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2,$$

kallas modellen ARCH(q)

- Om feltermens varians h_t för Y_t är

$$h_t = \omega + \alpha_1 \varepsilon_{t-1}^2 + \dots + \alpha_q \varepsilon_{t-q}^2 + \beta_1 h_{t-1} + \dots + \beta_p h_{t-p},$$

kallas modellen GARCH(p,q) ("Generalized ARCH")


- Notera: GARCH(0,q) = ARCH(q)

ARCH(q)- och GARCH(p,q)-modellval

- Modellval kan göras genom att jämföra informationskriterier som AIC eller BIC; alternativt med att jämföra kvalitet av prognoserna genom att dela in data i tränings, validerings och test data
- För att skatta parametrar i ARCH(q)- eller GARCH(p,q) med större p eller q behövs vanligtvis större datamängder som innehåller flera volatilitetskluster
- Vi tittar nu på daglig data över en 10-års period
- Exempel 10.3: Växelkursen SEK per EUR från 2008-2017. Medelvärde följer en slumpvandring (ARIMA(0,1,0)). Vi vill använda en lämplig GARCH(p,q)-variansmodell.


ARCH(q)- och GARCH(p,q)-modellering

- Exempel 10.3:
- Kursförloppet Y_t 2008-2017 visas i figuren
- Slumpvandring för medelvärdet:
$$Y_t = \mu + Y_{t-1} + \varepsilon_t$$




ARCH(q)- och GARCH(p,q)-modellering

- Exempel 10.3:
- Kvadrerade kursförändringar $(Y_t - Y_{t-1})^2$ 2008-2017 visas i figuren
- För att få ett bättre intryck över volatilitetskluster beräknar vi glidande medelvärden, MA(15), av dessa



ARCH(q)- och GARCH(p,q)-modellering

- Exempel 10.3:
- MA15 av kvadrerade kursförändringar visas i figuren
- Man ser en lång kluster av mycket stor volatilitet slutet av 2008 till mitten av 2009, och flera andra volatilitetskluster



ARCH(q)- och GARCH(p,q)-modellering

- Exempel 10.3: Efter analys av olika GARCH(p,q)-modeller väljer vi GARCH(1,1)-modellen vilken gav bäst BIC; analysen:

	Estimate	Std. Error	t value	Pr(> t)
mu	0.00052	0.00070	0.74	0.4587
omega	0.00002	0.00001	3.69	0.0002
alpha1	0.06594	0.00963	6.85	<0.0001
beta1	0.92139	0.01133	81.30	<0.0001

- Feltermens varians: $h_t = 0,00002 + 0,06594\varepsilon_{t-1}^2 + 0,92139h_{t-1}$
- Med den skattade modellen kan vi predicera variansen för morgondagen

T.ex. om variansen för idag hade beräknats till $h_t = 0,001$ (baserad på tidigare data med hjälp av denna GARCH(1,1)-modell) och

- Ingen kursförändring från igår till idag ($Y_t = Y_{t-1}$),
- Kursändring 0,1 från igår till idag ($|Y_t - Y_{t-1}| = 0,1$)

så blir variansen för imorgon

- $h_{t+1} = 0,000023 + 0,0659 \cdot 0 + 0,921 \cdot 0,001 = 0,000944$,
- $h_{t+1} = 0,000023 + 0,0659 \cdot 0,1^2 + 0,921 \cdot 0,001 = 0,001603$

R kod för analyserna innan

```
library(rugarch)
setwd("C:/Users/...") # write here where you have saved the data-files on your computer, if necessary
eursek2017 <- read.csv("SEKEUR_2017.csv", header = TRUE, sep = ";", dec=",")
eursek200817 <- read.csv("SEKEUR20082017.csv", header = TRUE, sep = ";", dec=",")

# ARCH(1) example
spec <- ugarchspec(variance.model = list(model="sGARCH",garchOrder = c(1, 0)), mean.model = list(armaOrder = c(0, 0),
                                                    include.mean = TRUE))
fit_a1 <- ugarchfit(spec = spec, data = eursek2017[-1, 3])
fit_a1

# GARCH(p, q) models, p=0, 1, 2, q=1, 2, 3; jämför Bayes Information Criterion; p=q=1 ger bäst resultat
for (p in 0:2){
  for (q in 1:2){
    spec <- ugarchspec(variance.model = list(model="sGARCH",garchOrder = c(q, p)), mean.model = list(armaOrder = c(0, 0),
                                                        include.mean = TRUE))
    fit <- ugarchfit(spec = spec, data = eursek200817[-1, 3])
    print(fit)
  }
}

spec <- ugarchspec(variance.model = list(model="sGARCH",garchOrder = c(1, 1)), mean.model = list(armaOrder = c(0, 0),
                                                    include.mean = TRUE))
fit_alb1 <- ugarchfit(spec = spec, data = eursek200817[-1, 3])
fit_alb1
```

Notera att GARCH-modellens parametrar ska vara i ordningen q, p

VAR modeller

- Med modellerna som vi betraktade hittills försöker man predicera framtiden av en serie med seriens egna historia
- Till exempel:
 - Framtidens växelkurs baserad på samma växelkursens historia
 - Framtidens BNP baserad på BNP-data bara
 - Sysselsättning i kommande kvartal baserad på sysselsättningen några år tillbaka
- Verkligheten är inte endimensionell: i många fall påverkar flera variabler en tidsserie
- Exempel: Framtidens BNP i Sverige skulle kunna bero på nutidens BNP, sysselsättningen och växelkursen

VAR modeller

- Vi har två tidsserier
 - $Y_{1,t} = a_1 Y_{1,t-1} + \varepsilon_{1,t}$
 - $Y_{2,t} = a_2 Y_{2,t-1} + \varepsilon_{2,t}$som ”påverkar varandra”
- En VAR (”Vector Autoregressive”) modell där serierna antas påverka varandra kan formuleras som ett system där man tillåter samspel mellan variablerna:
 - $Y_{1,t} = a_{11} Y_{1,t-1} + a_{12} Y_{2,t-1} + u_{1,t}$
 - $Y_{2,t} = a_{21} Y_{1,t-1} + a_{22} Y_{2,t-1} + u_{2,t}$
- Antaganden: $E[u_{1,t}] = E[u_{2,t}] = 0$ för alla t ,
 $E[u_{1,s} \cdot u_{2,t}] = 0$ för alla s och t (u_1 och u_2 är okorrelerade)
- Se [12.3 Vector autoregressions | Forecasting: Principles and Practice \(3rd ed\)](#)

VAR modeller

- Bra om vi undersöker dem individuella tidsserierna ($Y_{1,t}$, $Y_{2,t}$, ...) först och transformerar dem för att närma sig stationaritet (ska serien logaritmeras, säsongrenas, differentieras?)
- Analysera sedan dem transformerade tidsserierna med VAR
- Resultatet från VAR modellen kan undersökas om det finns signifikanta samband, men kausalitetsfrågan är här särskild knepig

VAR modeller

- Ränteläget i ekonomier påverkar växelkurserna och växelkurserna kan påverka ränteläget
- Exempel 10.4: Vi söker en modell samtidigt för räntor från 10-åriga statsobligationer från Sverige och Europa och för växelkursen SEK per EUR. Vi har daglig data för alla tre tidsserier. Hur kan en meningsfull modell se ut?

	Stats- obligationer	Internationella statsobligationer 10-års löptid	Valutor mot svenska kronor
Datum	SE GVB 10Y	EU 10Y	1 EUR
2017-11-27	0,711	0,341	9,8991
2017-11-28	0,695	0,34	9,9002
2017-11-29	0,739	0,389	9,9009
2017-11-30	0,732	0,367	9,9109
2017-12-01	0,718	0,31	9,984
2017-12-04	0,695	0,341	9,9504
2017-12-05	0,686	0,318	9,9942
2017-12-06	0,663	0,302	9,9329
2017-12-07	0,682	0,297	9,9488
2017-12-08	0,671	0,31	9,9831




Datakälla: Riksbanken

VAR modeller

- Exempel 10.4: Vad borde teoretisk hända med de två andra ”variabler” om
 - Sveriges riksbank påverkar marknaden så att räntan för statsobligationer från Sverige ökar?
 - Den Europeiska centralbanken påverkar marknaden så att räntan för statsobligationer från Europa ökar?
 - Växelkursen SEK per EUR ökar (dvs. kronan blir svagare mot euron)?

VAR modeller

- Tidsserier för räntor av 10-åriga statsobligationer från Sverige och Europa och deras dagliga förändringar. Förändringarna visar inte upp ett tydligt mönster och kan vara stationära (vi kan verifiera det med en test):



VAR modeller

- Exempel 10.4: VAR modellens skattningarna och hypotestest
- Två samband verkar vara viktiga:
 - Om den europeiska räntan ökar med 1%-enhet förväntas svenska räntan öka med 0,22%-enheter
 - Om den svenska räntan ökar med 1%-enhet förväntas växelkursen gå ned med 22 öre (0,22 kr), dvs. kronan blir starkare mot euron

		Estimate	Pr(> z)
D.swobl	D.swobl	-0.0021	0.980
	D.euobl	0.2201	0.007
	D.eursek	0.0222	0.765
	const	0.0002	0.933
D.euobl	D.swobl	0.0844	0.297
	D.euobl	0.0373	0.648
	D.eursek	0.0105	0.887
	const	0.0001	0.955
D.eursek	D.swobl	-0.2197	0.002
	D.euobl	0.1054	0.143
	D.eursek	-0.0144	0.826
	const	0.0020	0.250